Rapport synthétique de préparation et de transformation des données brutes (patients_brut.csv)

Ce script a permis de réaliser un nettoyage approfondi et une restructuration complète du jeu de données initial, afin de le rendre exploitable pour l'analyse statistique.

Dans un premier temps, les unités ont été harmonisées. Le poids mesuré en juin, initialement exprimé en livres, a été converti en kilogrammes avec un arrondi à l'unité pour faciliter la comparaison avec les mesures de janvier.
De même, les valeurs de glycémie ont été standardisées en g/L à partir de différentes unités d'origine (mmol/L ou mg/dL), identifiées en fonction des valeurs observées.

La variable **Sexe** a été normalisée sous les modalités "H" (homme) et "F" (femme).
La variable **Age** a été convertie en format numérique, puis nettoyée en remplaçant les valeurs aberrantes , identifiées via la méthode de l'écart interquartile (IQR) ,par des valeurs manquantes (NA).

La variable **Tension_sys_Tension_dia** a ensuite été scindée en deux colonnes distinctes, **Tension_sys** et **Tension_dia**, toutes deux converties en valeurs numériques.

Par ailleurs, la colonne **maladie**, contenant plusieurs pathologies sous forme de liste, a été transformée en format large : une colonne distincte a été créée pour chaque pathologie (Diabète, HTA, IRC, Asthme, etc.), avec une codification binaire ("Oui"/"Non") indiquant la présence ou l'absence de chaque maladie.

Enfin, les noms de variables ont été clarifiés et les colonnes réorganisées pour une meilleure lisibilité avant l'export du fichier final sous le nom **patients_tidy.csv**.

Ce jeu de données en format tidy constitue désormais une base propre, cohérente et directement exploitable pour les futures analyses statistiques.

Kenniche Redouane Mehdi Mehane